

尾盘信号模型训练与选股说明

目标：在 T 日 14:40 使用当时可获得的信息，排序次日开盘后前十分钟的候选，优先减少严重错误。

最值得跟踪的规则	折外结果	实际含义
8 因子二分类；每天分数前 2	15 天 × 2 = 30 只；严重错误 6/30 (20.0%)	24/30 为 0 或 1；其中真正 >1% 为 20/30

样本如何从 8,999 到 30



8,818 条特征完整、8,959 条标签完整：两项并行检查，不能把差值依次相减。
8,590 → 4,481 是按日期切出样本外评估窗口；4,481 → 30 是每日排序取前 2。

样本单位是“股票 × 信号日”。8,999 条为 14:40 涨幅 3%-6% 的候选；8,590 条同时满足特征、标签和可判定的涨停代理条件。8,818 条特征完整与 8,959 条标签完整是并行检查，不能把差值逐项相减。次晨标签完整性只用于历史训练和回测。

按日期滚动训练三次：每次只用更早交易日训练，预测其后 5 个交易日。15 个测试日合计产生 4,481 条互不重复的折外预测；每条均有模型分数，最后才按“每天前 2”收窄到 30 只。

目标与通过口径

T 日 14:50 分钟最新价作为假设买价， $r = T+1$ 日 09:31-09:40 最高价 / 假设买价 - 1。 $r > 1\%$ 记为 1； $r < 0.5\%$ 记为 -1；其余记为 0。二分类把 0 和 1 合并为“通过”，仅真实 -1 是“严重错误”。

“通过”不等于达到 1% 卖价：30 只中 4 只属于 0 类。分钟最高价触及某价也不保证委托成交。

一 数据时点与变量实现

时间边界：先取可用信息，再观察结果



T 日收盘值、14:50 价、T+1 行情和事后涨停标记均不进入 14:40 模型。

T 日昨收参考价取历史日表 preclose，作为实时行情可取得的昨收价代理；日 K、流通股本与流通市值只用 T-1 及更早记录。14:40 量价来自 full 分钟 K。历史入库时间不作为可用时间限制，前提是线上实时行情接口可取得同口径数据。

实际用于 30 只排序的 8 个因子

因子	计算口径（全部截至 14:40）	形式
当日涨幅	14:40 价 / T 日昨收参考价 - 1	原值
量比	09:31-14:40 累计成交股数 × 240 / (220 × 前 5 日均量)	原值
换手率	截至 14:40 成交股数 / T-1 流通股本 × 100	原值
流通市值	T-1 流通市值 / 1 亿；单位亿元	原值
5 日量增标志	前 5 日成交量中，存在按日期严格递增的 4 日子序列	0/1
均线多头	T-1 及更早日 K 计算 MA5 > MA10 > MA20	0/1
14:40 价在均线上	14:40 价 > MA5、MA10、MA20 的最大值	0/1
日内低点均在均线上	09:31-14:40 每根分钟 K 最低价均 > 三条均线	0/1

分钟 K 成交量由“手”乘 100 转为股。MA 先由 T-1 复权收盘序列计算，再按 T 日昨收参考价 / T-1 复权收盘价映射到 T 日价格尺度；近 20 日有 >1% 复权价格断点的候选排除。

20 因子版本另加入：昨收参考价、14:40 价格、日内累计成交量、前 5 日逐日成交量、前 5 日均量、MA5 / MA10 / MA20。大盘、行业、资金流向虽为研究方向，本轮模型没有使用。

二 模型结构与训练方式

本轮比较 20 因子三分类逻辑回归、8 因子三分类逻辑回归、20 因子浅决策树；按“0/1 都通过”的新口径，另训练相同 8 因子的二分类逻辑回归。最终 30 只来自最后一种。

模型	输出与结构	作用
8 因子二分类逻辑回归	输出 p(通过)；L2 正则 C=0.2	每日按分数排序
8 / 20 因子三分类逻辑回归	Softmax 输出 p(-1)、p(0)、p(1)；C=0.2	比较原三档目标
20 因子浅决策树	最大深度 3；每叶至少 120 个样本	检视条件，未做最终规则

二分类公式： $p(\text{通过} \mid x) = 1 / [1 + \exp(-s)]$ ， $s = b + \text{sum}(w_j \times z_j)$ 。四个连续变量在每个训练折分别按 $z = (\text{原值} - \text{训练均值}) / \text{训练标准差}$ 转换；四个标志保持 0/1。三分类是各类别线性得分的 Softmax： $p(k \mid x) = \exp(s_k) / \text{sum} \exp(s_j)$ 。

时间折	训练信号日 / 样本	随后测试信号日 / 折外预测
1	08-25 至 09-07 / 4,109	09-08 至 09-14 / 1,061
2	08-25 至 09-14 / 5,170	09-15 至 09-21 / 2,318
3	08-25 至 09-21 / 7,488	09-22 至 09-29 / 1,102

训练窗口会重用更早交易日样本，每条测试记录只在其中一个测试折预测一次；没有重采样。测试日共 1,518 条 -1、744 条 0、2,219 条 1。

真实公式示例：第 3 折二分类

第 3 折训练 7,488 条样本，截距 $b = +0.9396$ 。下列系数为该折真实拟合值；连续变量系数对应“增加 1 个训练标准差”，标志变量对应“由 0 变 1”。另两折各有自己的系数，不能拿这一套公式重算全部 15 天。

因子	系数	因子	系数
当日涨幅	+0.0593	量比	-0.1632
换手率	-0.0756	流通市值	+0.0147
5 日量增	+0.0708	均线多头	-0.0901
14:40 价在均线上	-0.1663	日内低点均在均线上	+0.1821


第 3 折连续因子标准化参数（训练均值 / 标准差）：涨幅 0.040990 / 0.008244；量比 1.528231 / 0.806173；换手率 4.400397 / 4.088819；流通市值 155.854965 / 476.948791。

系数是控制其它因子后的条件方向；部分均线标志在三个折间变号，尚不能提炼为稳定单因子规律。浅树多数叶子直接判 1，且有 $MA10 \leq 25.63$ 这类绝对价格切分，业务解释与区分能力都偏弱。

三 模型前后的规则如何得到 30 只

阶段	规则与作用
模型前：候选	T 日 14:40 涨幅 3%-6%；非 ST，且涨幅低于对应板块涨停幅度代理阈值。
模型前：特征质量	220 根 09:31-14:40 分钟 K 完整且非回填；20 日连续历史、T-1 估值完整；去掉近 20 日复权价格断点。
历史回测：标签质量	T 日 14:50 买价代理及 T+1 前十分钟行情完整，才能计算训练标签和回测结果；线上 14:40 选股不使用此项。
模型：逐折评分	8 因子二分类逻辑回归，对 4,481 条测试候选逐一输出 p(通过)。
模型后：排序	每日按 p(通过) 从高到低取前 2；15 日得到 30 只。无绝对分数阈值，也无每周配额。
结果审计	14:50 临近涨停代理、T 日最终涨停标记只用于事后核查，不参与 14:40 训练或入选。

同一二分类模型：多选一些，严重错误也随之增多



规则 / 对照	入选	严重错误 -1	通过 0/1	真正 >1%
全部折外候选	4,481	1,518 / 33.9%	2,963 / 66.1%	2,219 / 49.5%
20 因子三分类硬判 1	4,343	1,452 / 33.4%	2,891 / 66.6%	2,164 / 49.8%
8 因子二分类每日前 2	30	6 / 20.0%	24 / 80.0%	20 / 66.7%
同模型每日前 3	45	11 / 24.4%	34 / 75.6%	26 / 57.8%
同模型每日前 5	75	23 / 30.7%	52 / 69.3%	39 / 52.0%

33.9% 是按 4,481 条记录加权的全池严重错误率；图中的 38.2% 是 15 天候选错误率的等权均值，用于比较“每日固定取前 K”。从前 2 扩到前 5，额外 45 只中有 17 只为 -1。

四 结果怎样理解

每日前 2 的 6/30 指 30 次入选中有 6 次真实涨幅低于 0.5%，并非“准确率 20%”。按当前容错口径，通过率为 $24/30 = 80.0\%$ ；按原本 1% 卖价目标，真正达到的是 $20/30 = 66.7\%$ 。这三项应并列看。

三个测试折的每日前 2 严重错误分别为 4/10、1/10、1/10。2026-09-09 的两只都为 -1，逐日波动明显。全池通过排序 AUC 仅 0.506；若按二分类分数 ≥ 0.80 入选，19 条中有 9 条严重错误。模型分数尚不能解释为已校准的真实概率。

20 因子三分类 $p(1) \geq 0.70$ 的探索性规则只选出 16 条，其中 3 条严重错误，有 7 个测试日空选。这个阈值和“每日前 2”均是在同一批测试日结果上比较出来，尚未经过新的日期独立确认。浅树折外总体准确率约 49.9%，接近候选池真实 1 类占比 49.5%，没有形成更清晰的执行规则。

现阶段边界与下一轮验证

三种重点规则的并集共 74 条不同股票日期；事后 14:50 非临近涨停代理检查全部通过，T 日最终涨停标记均为 0。该核查只说明历史样本的可交易性代理：没有手续费、滑点、盘口容量和真实委托模拟。二分类每日前 2 中另有 2/30 的次晨前十分钟最高价仍低于假设买价。

下一轮应固定少量候选规则，用新日期持续记录每日前 2 的严重错误率、真正 >1% 比例与逐日波动。若要允许空选，放弃条件也需在新数据上验证。线上执行须核实 14:40 实时昨收、分钟量价与历史回放口径一致。

代码、数据与复现

用途	仓库路径
标准样本与时点	scripts/build_automl_tail_standard.py docs/stock_automl_runs/20261008_tail_standard/summary.json
三分类与决策树	scripts/experiment_automl_tail_three_class.py docs/stock_automl_runs/20261008_tail_three_class/summary.json
二分类与严重错误复核	scripts/analyze_automl_tail_critical.py docs/stock_automl_runs/20261008_tail_critical_review/summary.json

复现顺序：生成标准样本 → 三分类实验 → 严重错误复核。逐股数据与 Excel 在仓库忽略的 outputs/ 目录；本文件只记录聚合口径，不复制原始行情。